Влияние различий средних на обнаружение корреляционных паттернов при интерпретации кластеров

Аннотация

Интерпретация кластеров требует выявления не только различий отдельных признаков, но и зависимостей между ними, которые могут не отражаться в рейтингах важности. Цель работы состоит в оценке влияния межгрупповых различий средних на обнаружение признаков, участвующих в корреляционном паттерне, и в сравнении способов измерения их важности. Для этого используется контролируемый синтетический эксперимент с двумя заранее заданными группами, в которых корреляции пары признаков различаются, а их средние и дисперсии совпадают; разность средних дополнительного признака последовательно увеличивается при неизменном распределении исходной пары. Сравниваются случайный лес с перестановочной важностью по доле правильных ответов и логарифмической функции потерь, локальные интерпретируемые объяснения, метод главных компонент и прямое сравнение корреляций; основной показатель определяется как частота одновременного включения обоих признаков пары в тройку наиболее важных по результатам двадцати независимых повторов. В базовом эксперименте при увеличении разности средних дополнительного признака от нуля до четырёх внутригрупповых стандартных отклонений эта частота у случайного леса снизилась со ста до нуля процентов для важности по доле правильных ответов и со ста до семидесяти процентов для важности по логарифмическим потерям. Метод главных компонент и прямое сравнение корреляций сохраняли оба признака во всех повторах, тогда как выбранный вариант локальных объяснений редко выделял пару уже при отсутствии различий средних. Полученные предварительные результаты показывают необходимость учитывать способ оценки важности при интерпретации структуры групп и отделять полноту выделения участников паттерна от качества объяснения предсказаний классификатора.

1 Введение

При интерпретации кластеров требуется установить, какие свойства данных характеризуют выделенные группы. Такие свойства включают различия средних отдельных признаков и различия зависимостей между ними. Цель исследования — определить, как усиление первого типа различий влияет на обнаружение признаков, участвующих во втором.

Для интерпретации готового разбиения применяются модели, предсказывающие принадлежность к кластеру, локальные объяснения и методы снижения размерности. Connor и соавторы [1] сравнивают случайный лес, LIME и метод главных компонент на данных с известными паттернами. LIME строит локальное приближение предска-

Выпускная квалификационная работа.

заний модели [2], а разложение DIP разделяет самостоятельные вклады признаков, взаимодействия и зависимости [3].

Эти подходы оценивают разные характеристики: влияние признака на прогноз, поведение модели в окрестности объекта или структуру вариации данных. Поэтому высокое качество классификации и корректное объяснение предсказания не гарантируют полного описания межгрупповых различий. Кроме того, стандартный случайный лес может недостаточно учитывать некоторые взаимодействия [4], что необходимо отделять от ограничений самой процедуры интерпретации.

В работе проводится сравнение при фиксированном корреляционном паттерне и изменяемом различии средних дополнительного признака. Такая постановка позволяет проследить изменение рейтингов при изменении одного фактора. Задачи исследования — измерить частоту выделения участников паттерна, сопоставить способы оценки важности и проверить устойчивость результатов к параметрам данных и методов.

Первый эксперимент проводится на синтетических данных с заданными групповыми метками. Для каждого независимого повтора создаются обучающая и тестовая выборки, затем изменяется только сдвиг среднего дополнительного признака. Предварительный результат — различная чувствительность двух перестановочных оценок важности одного классификатора к этому сдвигу. Практический смысл сравнения заключается в выборе способов интерпретации, сохраняющих информацию об исследуемой структуре групп.

2 Постановка задачи

Даны обучающая и независимая тестовая выборки с фиксированными групповыми метками. Требуется оценить, как изменение различий средних одного признака влияет на выделение другой пары признаков, корреляции которой различаются между группами.

Рассматриваются две равные группы A и B. Признаки X и Y имеют стандартные нормальные распределения в обеих группах; их корреляция равна 0,8 в группе A и 0 в группе B. Признак Z независим от X и Y внутри каждой группы и имеет единичную дисперсию. Средние Z сдвигаются симметрично относительно нуля, а разность между ними последовательно увеличивается. Распределение пары X–Y внутри групп при этом не меняется. Остальные признаки представляют собой независимый стандартный нормальный шум.

Каждый метод формирует рейтинг признаков. Основной критерий качества — доля независимых повторов, в которых X и Y одновременно входят в тройку наиболее важных. Дополнительно оцениваются ранги признаков и качество классификатора на тестовой выборке. Метрика характеризует выделение участников паттерна, а не восстановление самой зависимости.

Важность случайного леса оценивается изменением доли правильных ответов или логарифмических потерь после перемешивания признака на тестовой выборке. Для LIME используются усреднённые абсолютные веса локальных объяснений, для метода главных компонент — абсолютные нагрузки первой компоненты. Прямое сравнение корреляций служит базовым методом. На первом этапе группы заданы заранее, что позволяет исследовать интерпретацию отдельно от алгоритма кластеризации.

3 Базовый эксперимент и первые результаты

Использованы выборки по 600 объектов для обучения и независимой проверки, с равным числом объектов каждой группы. Размерность 10, число повторов 20, значения разности средних Z: 0; 0,5; 1; 2; 3; 4. Внутри повтора используются одинаковые исходные объекты и случайные величины при всех значениях Δ.

В таблице приведены значения основной метрики для крайних значений сдвига. Вариант метода главных компонент со стандартизацией внутри групп служит контролем: такая обработка устраняет добавленный сдвиг среднего.

Метод	$\Delta = 0$	$\Delta = 4$
Случайный лес: важность по accuracy	100%	0%
Случайный лес: важность по log loss	100%	70%
LIME: усреднённые абсолютные веса	5%	5%
Главные компоненты: общая стандартизация	100%	100%
Главные компоненты: внутри групп	100%	100%
Прямое сравнение корреляций	100%	100%

Таблица 1: Включение обоих признаков X, Y в тройку наиболее важных.

Средняя доля правильных ответов случайного леса выросла с 57,8% до 97,8%. При этом выделение пары по перестановочной важности существенно зависело от выбранной меры качества. Результат LIME нельзя объяснить только сдвигом Z, поскольку пара редко выделялась уже при $\Delta = 0$.

Число повторов ограничивает точность оценок: для частот 0%, 70% и 100% интервалы Wilson уровня 95% составляют соответственно $[0; 16{,}1]\%$, $[48{,}1; 85{,}5]\%$ и $[83{,}9; 100]\%$. Полученные результаты относятся к выбранному генератору и настройкам методов. Далее требуется проверить другие силы корреляции, объёмы выборки и размерности данных.

Список литературы

[1] Benjamin Connor, Anna Jurek-Loughrey, Lu Bai, and Muhammad Fahim. Beyond feature importance: A comparative analysis of pattern detection methods in cluster interpretation, 2026. URL `https://arxiv.org/abs/2608.05880`.

[2] Marco Tulio Ribeiro, Sameer Singh, and Carlos Guestrin. "Why Should I Trust You?": Explaining the Predictions of Any Classifier. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 1135–1144, 2016. doi: 10.1145/2939672.2939778. URL `https://arxiv.org/abs/1602.04938`.

[3] Gunnar König, Eric Günther, and Ulrike von Luxburg. Disentangling interactions and dependencies in feature attributions. In *Proceedings of the 28th International Conference on Artificial Intelligence and Statistics*, volume 258 of *Proceedings of Machine Learning Research*, pages 2134–2142, 2025. URL `https://proceedings.mlr.press/v258/konig25a.html`.

[4] Ricardo Blum, Munir Hiabu, Enno Mammen, and Joseph Theo Meyer. Pure interaction effects unseen by random forests, 2025. URL `https://arxiv.org/abs/2406.15500v2`. Version 2.